Aula 1 - Introdução

Introdução ao aprendizado de máquina - UEMA 2025

Thiago S. F .Silva

2025-12-09

Apresentações

Eu: Thiago Silva

Formação:

- Biologia (UFRN, 2002)
- Sensoriamento Remoto (INPE, 2004)
- Geografia Física (UVic, 2009)

Interesses:

- Funcionamento e dinâmica de ecossistemas
- Efeitos das mudanças globais sobre a biota
- Interface entre Ecologia, Computação e Geociências
- "Ecologia Digital"

Vocês?

Perfil discente

Nunca ouvi falar / Já ouvi falar / Já usei / Uso sempre

- Programação em R
- Programação em outras linguagens
- Estatística descritiva
- Modelos Lineares (regressão/ANOVA)
- Sensoriamento Remoto
- SIG
- Machine Learning

Perfil discente

Nunca ouvi falar / Já ouvi falar / Já usei / Uso sempre

- CSV
- JSON
- shapefile
- GeoTiff
- Git
- GitHub

O que esse curso é sobre?

- Análise **preditiva** de dados
- Introdução ao aprendizado de máquina (*machine learning*)
- Conversa sobre princípios e práticas científicas
- Ponto de partida para o seu próprio aprendizado

O que esse curso não é sobre?

- Inferência estatística (mas vamos tocar nela várias vezes)
- “IA” - mas vamos contextualizar.

Ciência de dados / data science ?

Wikipedia:

A *ciência de dados* é um campo **interdisciplinar** que utiliza *estatística*, *computação*, *método científico*, *visualização científica*, *algoritmos* e *sistemas* para **extrair ou extrapolar conhecimento** a partir de **dados** potencialmente *ruidosos*, *estruturados* ou *não-estruturados*.[2]

A ciência de dados também integra **conhecimento especializado** do domínio de aplicação (ex. ciências naturais, ciências sociais, medicina).

Machine Learning?

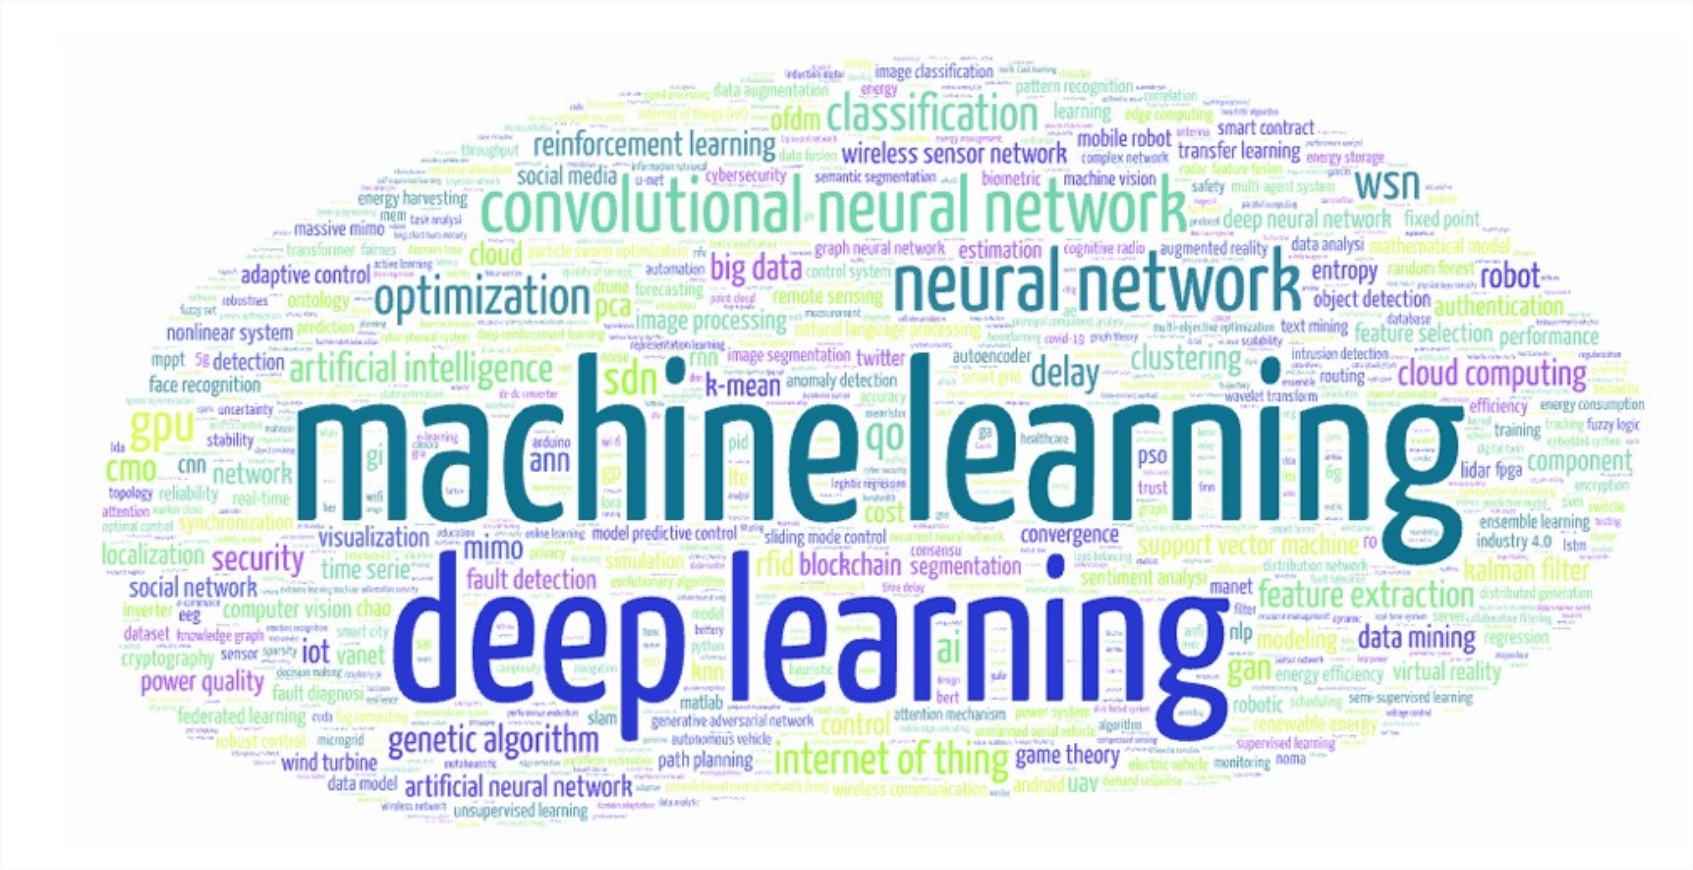

Figure 1: Fonte: Xiaochen, Zhou, et al. "DeepDiveAI: Identifying AI Related Documents in Large Scale Literature Data." arXiv preprint arXiv:2408.12871 (2024).

Terminologia

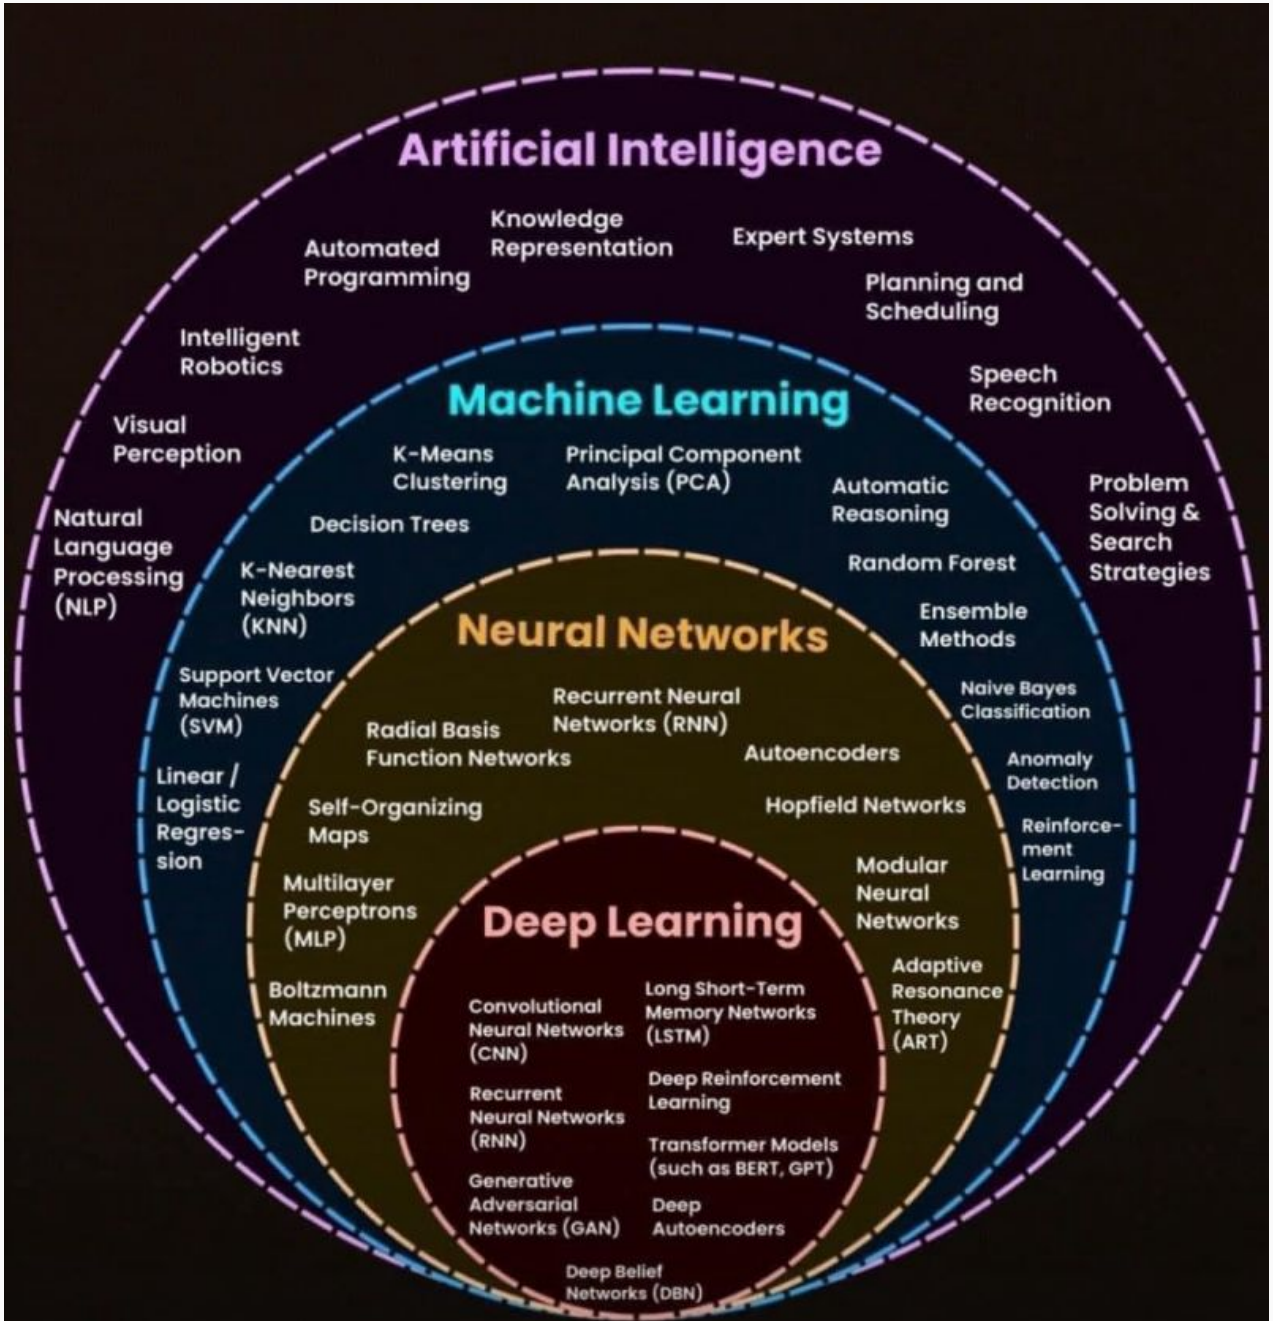

Estatística?

Matemática vs. Estatística?

- O que é Estatística?
- Por que usamos Estatística?

Estatística

- Exploração
- Confirmação
- Predição

Estatística

- **Exploração**: sem expectativas prévias, perguntas abertas.
- **Confirmação**: hipóteses pré-estabelecidas
- **Predição**: foco em gerar novos dados

Exemplo:

- **Exploração:** Quão intenso é o efeito da redução de disponibilidade hídrica sobre o crescimento da espécie de planta *Plantus plantus*?

Exemplo:

- **Exploração:** Quão intenso é o efeito da redução de disponibilidade hídrica sobre o crescimento da espécie de planta *Plantus plantus*?
- **Confirmação:** A redução em 50% na disponibibilidade hídrica esperada para a década de 2100 resultará em redução de pelo menos 30% no crescimento de *Plantus plantus*.

Exemplo:

- **Exploração:** Quão intenso é o efeito da redução de disponibilidade hídrica sobre o crescimento da espécie de planta *Plantus plantus*?
- **Confirmação:** A redução em 50% na disponibibilidade hídrica esperada para a década de 2100 resultará em redução de pelo menos 30% no crescimento de *Plantus plantus*.
- **Predição:** Qual o crescimento esperado para *Plantus plantus* em 2100 sob os cenários A, B e C de mudanças climáticas?

Machine Learning

- Utiliza **análise exploratória** para entendimento dos *dados*
- Não se preocupa com **confimação**.
- Especializado em gerar as melhores **predições** possíveis.

Machine learning é estatística?

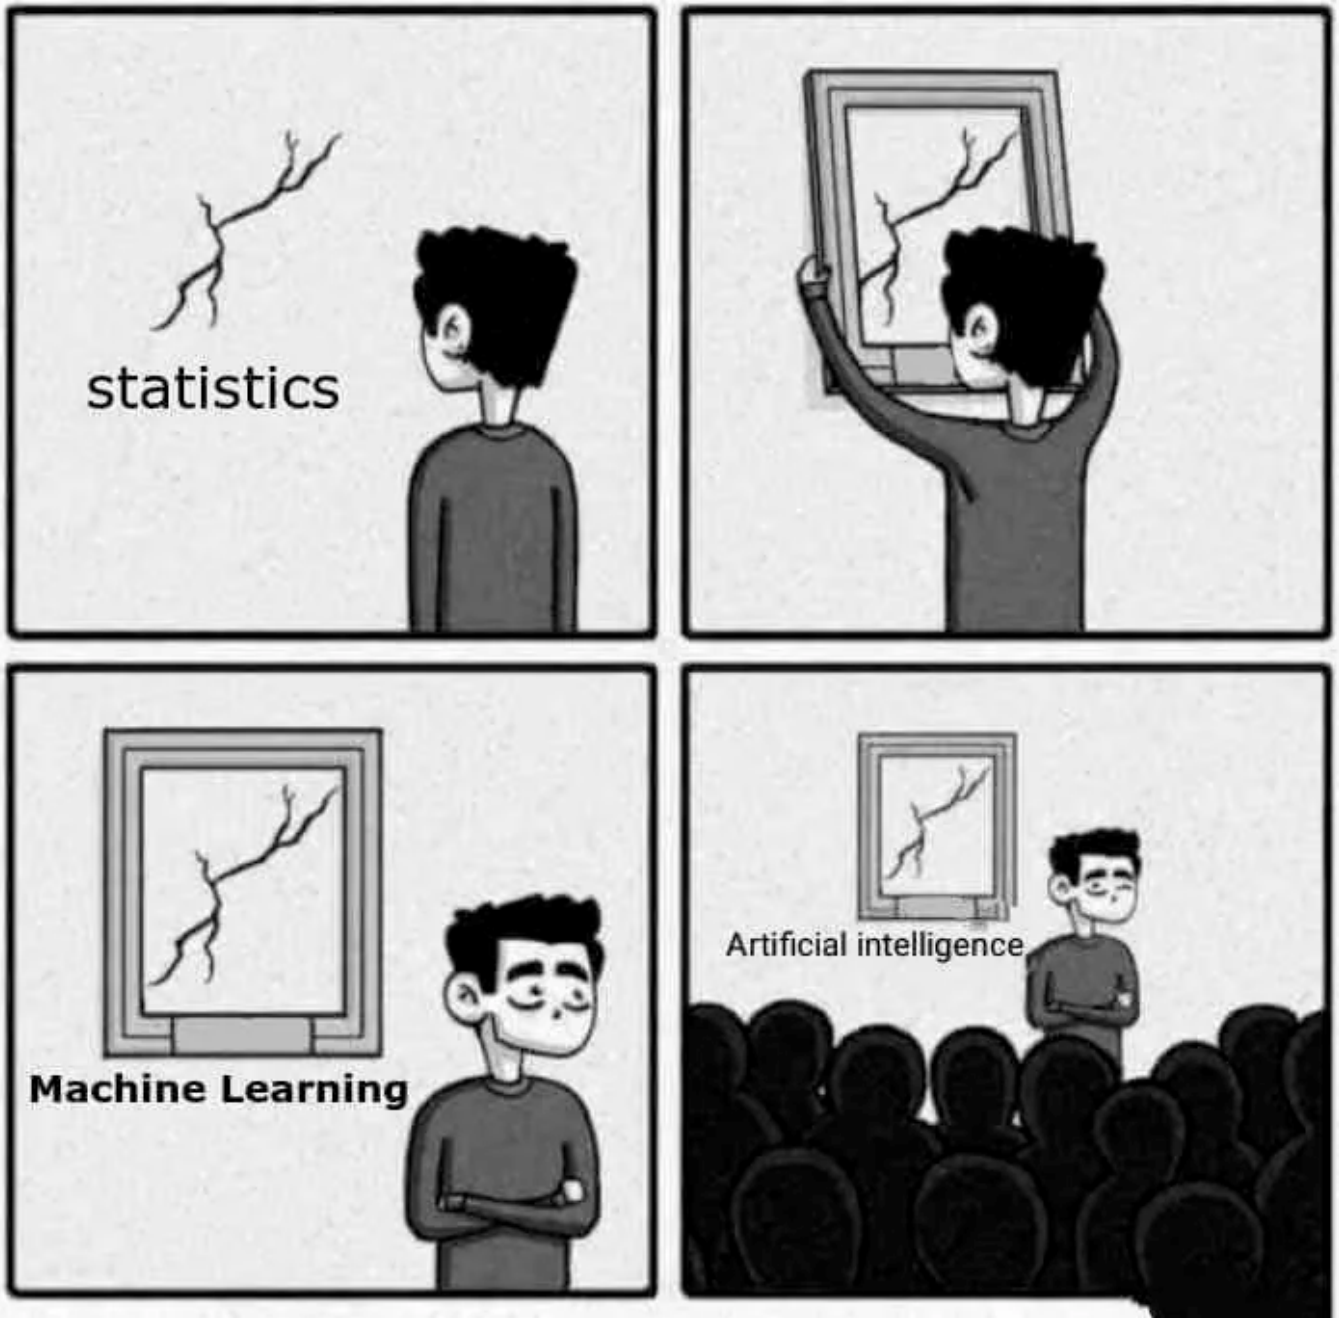

Prova oral de estatística

```
Call:
lm(formula = y ~ x, data = df)

Residuals:
    Min      1Q  Median      3Q     Max
-377.94  -66.26   -4.97   66.86  281.84

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)    5.229      6.277   0.833  0.40501
x              0.341      0.111   3.071  0.00219 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 100.4 on 998 degrees of freedom
Multiple R-squared:  0.009364,  Adjusted R-squared:  0.008372
F-statistic: 9.434 on 1 and 998 DF,  p-value: 0.002188
```

Gráfico do Modelo

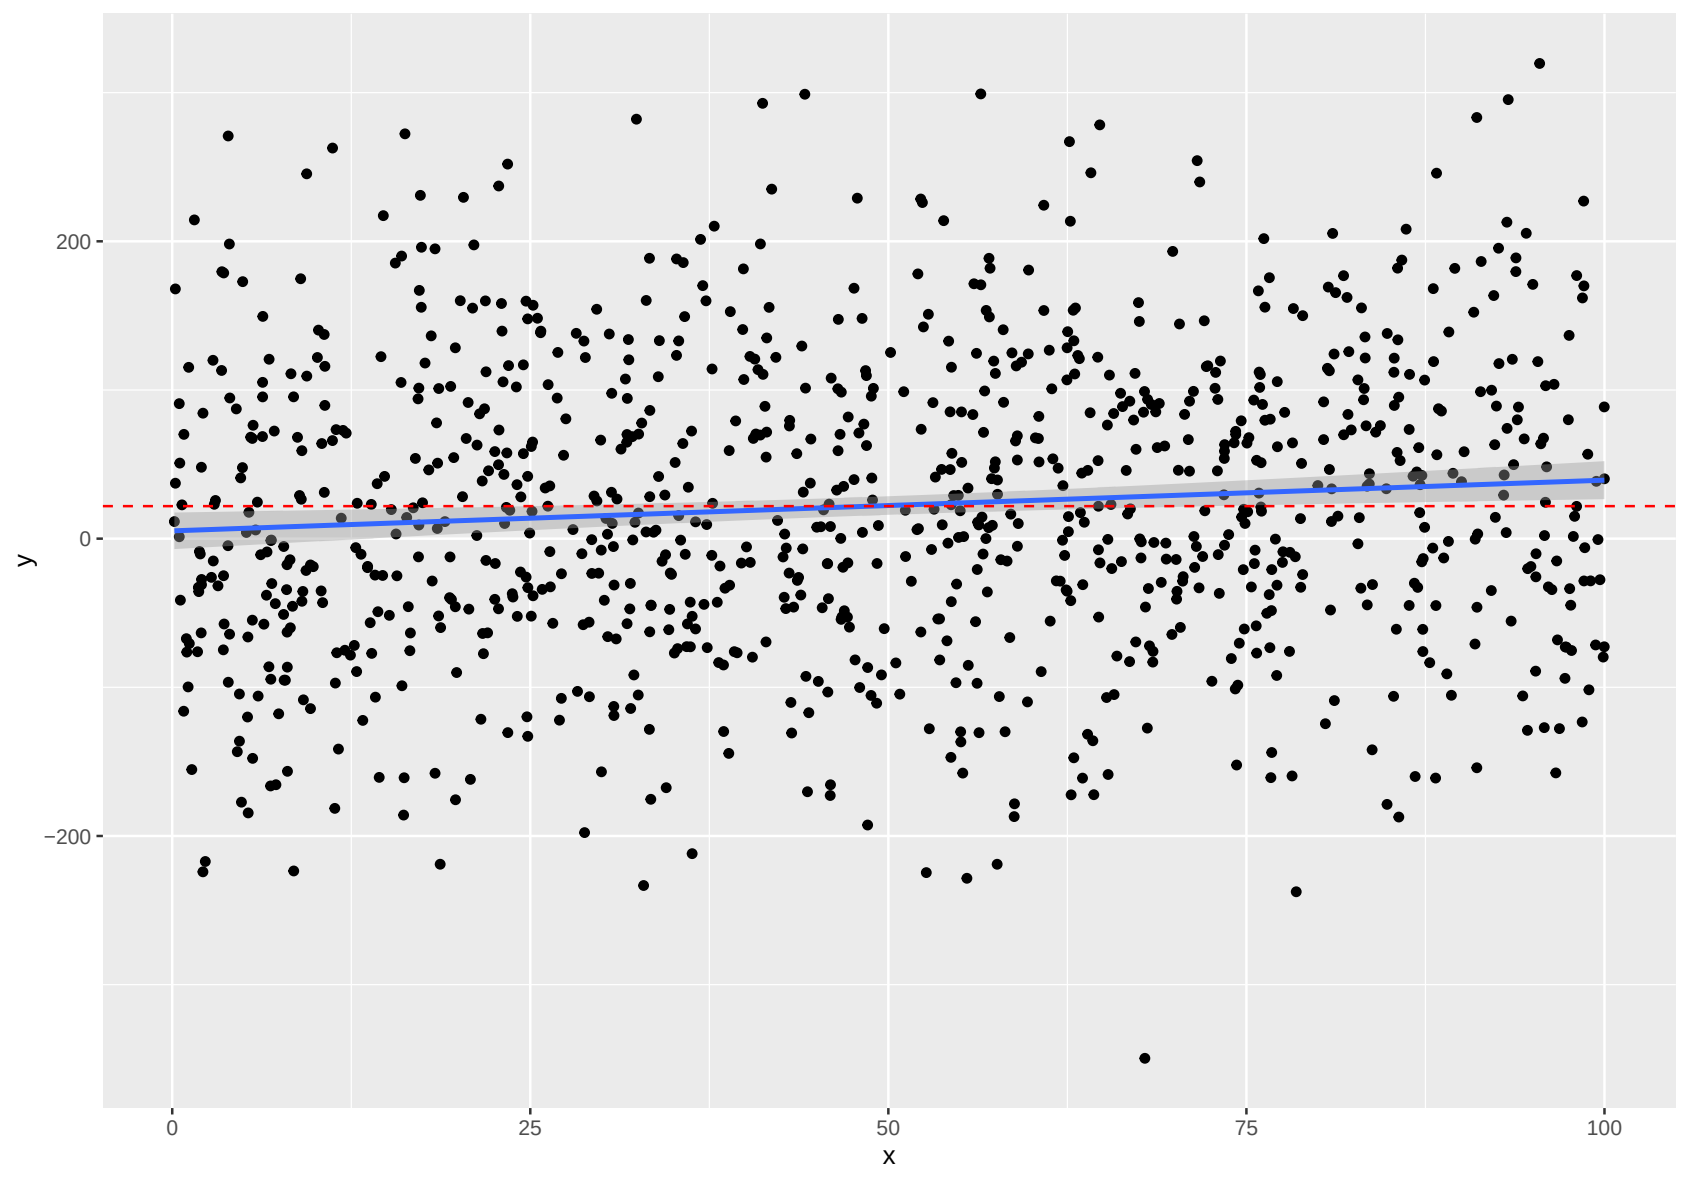

Observado vs Predito

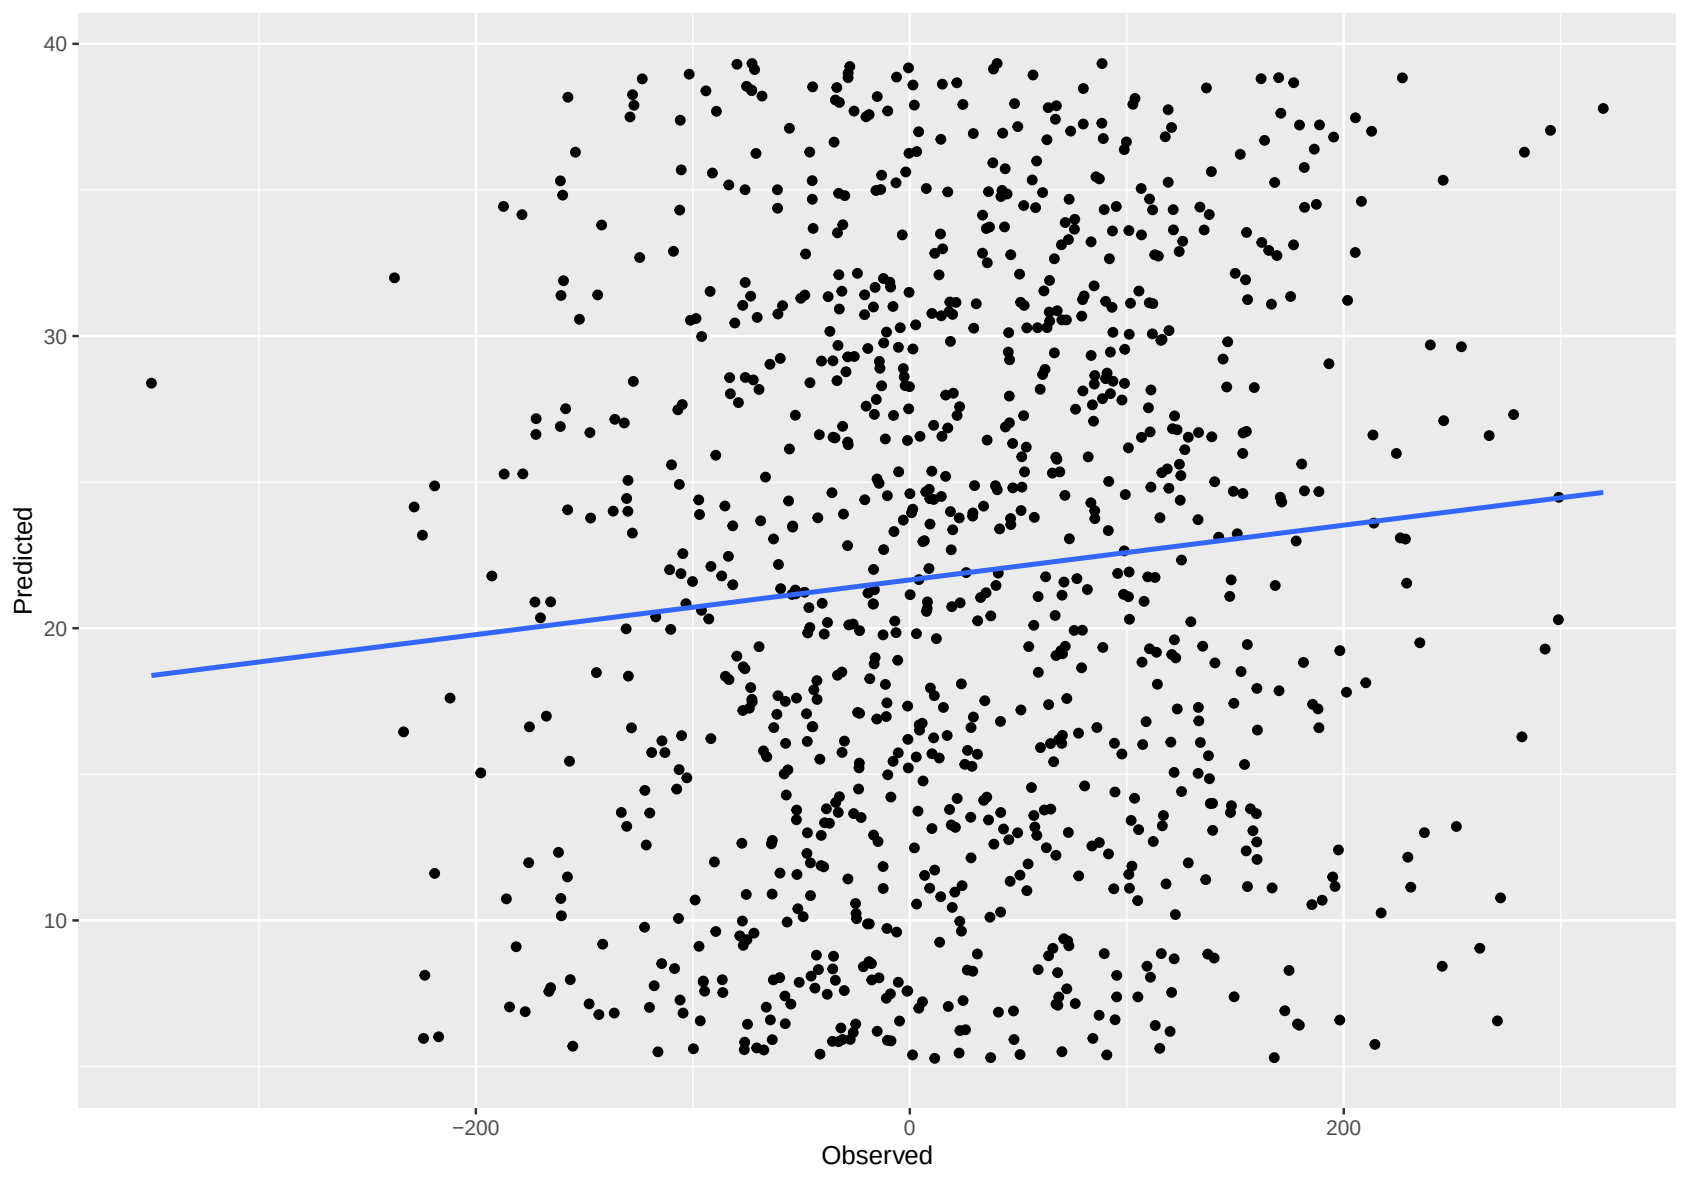

Bom modelo ou mau modelo?

- Excelente do ponto de vista *confimatório*.

Bom modelo ou mau modelo?

- Excelente do ponto de vista *confimatório*.
- Péssimo do ponto de vista *preditivo*.

Erro, erro, erro

Quando estamos preocupados com predição, o que realmente importa é minimizar o **erro**.

Pouco erro

O modelo abaixo tem bem pouco erro - estamos satisfeitos?

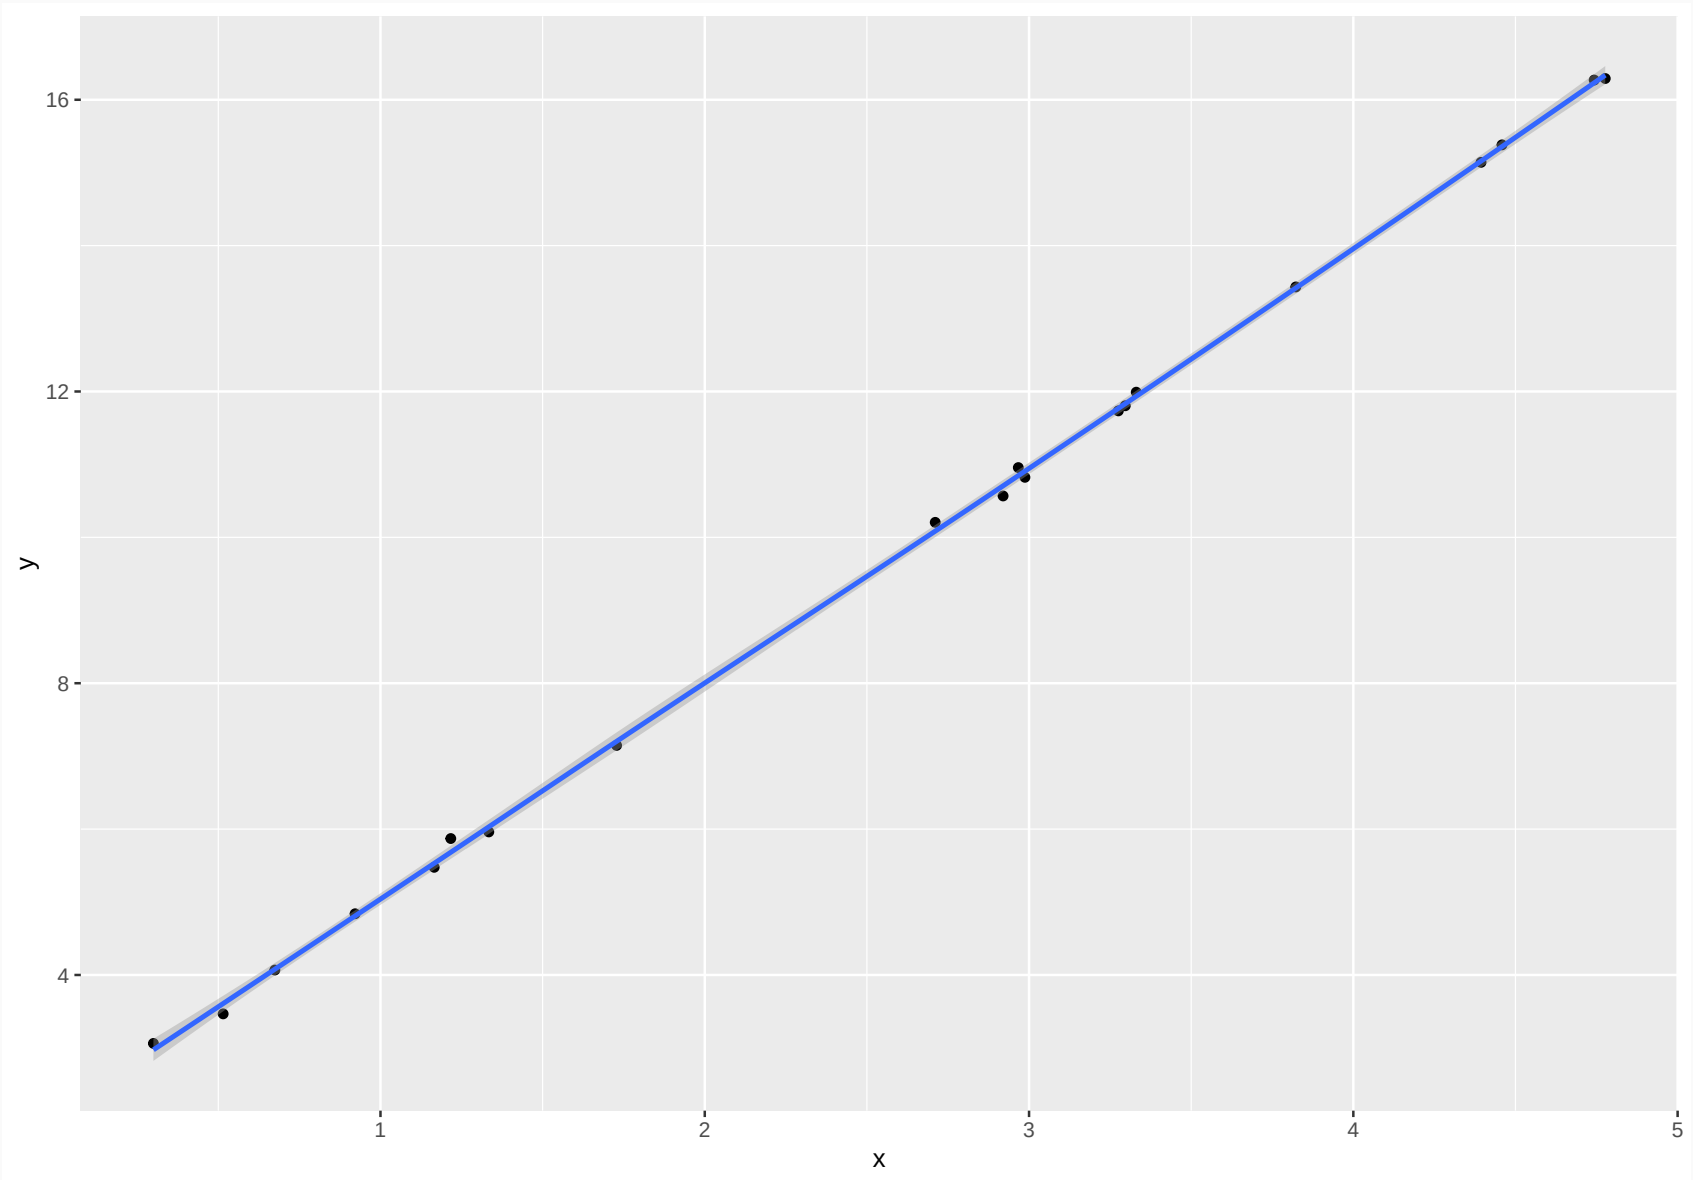

Validação e teste

Workflow de uma análise estatística 'tradicional':

1. Preparação dos dados

Validação e teste

Workflow de uma análise estatística 'tradicional':

1. Preparação dos dados
2. Análise descritiva

Validação e teste

Workflow de uma análise estatística 'tradicional':

1. Preparação dos dados
2. Análise descritiva
3. Visualização de dados

Validação e teste

Workflow de uma análise estatística 'tradicional':

1. Preparação dos dados
2. Análise descritiva
3. Visualização de dados
4. Ajuste do modelo (teste estatístico)

Validação e teste

Workflow de uma análise estatística 'tradicional':

1. Preparação dos dados
2. Análise descritiva
3. Visualização de dados
4. Ajuste do modelo (teste estatístico)
5. Interpretação dos resultados

Validação e teste

Workflow de uma análise preditiva:

1. Preparação dos dados

Validação e teste

Workflow de uma análise preditiva:

1. Preparação dos dados
2. Análise descritiva

Validação e teste

Workflow de uma análise preditiva:

1. Preparação dos dados
2. Análise descritiva
3. Visualização de dados

Validação e teste

Workflow de uma análise preditiva:

1. Preparação dos dados
2. Análise descritiva
3. Visualização de dados
4. **Divisão dos dados em *treinamento* e *teste***

Validação e teste

Workflow de uma análise preditiva:

1. Preparação dos dados
2. Análise descritiva
3. Visualização de dados
4. **Divisão dos dados em *treinamento* e *teste***
5. Ajuste do modelo

Validação e teste

Workflow de uma análise preditiva:

1. Preparação dos dados
2. Análise descritiva
3. Visualização de dados
4. **Divisão dos dados em *treinamento* e *teste***
5. Ajuste do modelo
6. **Otimização e validação do modelo**

Validação e teste

Workflow de uma análise preditiva:

1. Preparação dos dados
2. Análise descritiva
3. Visualização de dados
4. **Divisão dos dados em *treinamento* e *teste***
5. Ajuste do modelo
6. **Otimização e validação do modelo**
7. **Teste do modelo**

Detalhes técnicos

Por que o curso é baseado em *R*?

- Porque todo profissional nas ciências naturais precisa saber o mínimo de programação.
- Fácil de instalar e usar.
- Criado especificamente para análise de dados.
- 'Padrão' nas ciências naturais.

Detalhes técnicos

Mas e o tal do *Python*?

- Sim, é a principal linguagem para data science.
- Mais complicada pra instalar e começar a usar.
- Menos popular no mundo acadêmico.
- É uma linguagem criada para uso geral, e por isso muito 'maior' do que o R.
  - No. Pacotes no CRAN: 23035
  - No. Pacotes no PyPI: 709358

Entrando no “Tidyverso”

Tidyverse: um conjunto de pacotes do R que ‘redefiniu’ a linguagem e a maneira de trabalhar, com ênfase em ciência de dados.

https://tidyverse.org/

Tidyverse

O conceito central do tidyverse é o operador '*pipe*' (cano), que conecta operações sequenciais:

%>% ou |> a partir do R 4.0

Um exemplo

```
summary(iris)
```

```
  Sepal.Length    Sepal.Width     Petal.Length    Petal.Width
 Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
 1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
 Median :5.800   Median :3.000   Median :4.350   Median :1.300
 Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
 3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
 Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
       Species
 setosa    :50
 versicolor:50
 virginica :50
```

Sem pipe

```r
sel <- iris[iris$Sepal.Length > 6,]
sel <-  sel[,"Petal.Width"]
res <- mean(sel)
res
```

```
[1] 1.847541
```

Sem pipe

```
# Ou tudo em uma linha
res <- mean(iris[iris$Sepal.Length > 6, "Petal.Width"])
res
```

```
[1] 1.847541
```

Com pipe

```
library(tidyverse)
res <- iris %>%
  filter(Sepal.Length > 6) %>%
  summarise(mean_pw = mean(Petal.Width))
res
```

```
   mean_pw
1 1.847541
```

Perguntas?

Para amanhã:

Gerenciamento e visualização de dados

- Inclui práticas no R
- Se possivel trazer seu computador com R, RStudio e os pacotes básicos já instalados (programa de curso que eu enviei)