Aula 5 - Geoprocessamento e ML

Introdução ao aprendizado de máquina - UEMA 2025

Thiago S. F. Silva

2025-12-17

Parte I - Introdução e Terminologia

Sensoriamento Remoto

O que é sensoriamento remoto?

Sensoriamento Remoto

O que é sensoriamento remoto?

- Uma *medida* da quantidade de REM refletida pela superfície.
- Essa medida é organizada na forma de uma *imagem*.

Geoprocessamento: SR + SIG + GNSS

Estrutura de uma imagem de SR

- Formato **raster**: bandas, pixels, ND (ou DN)

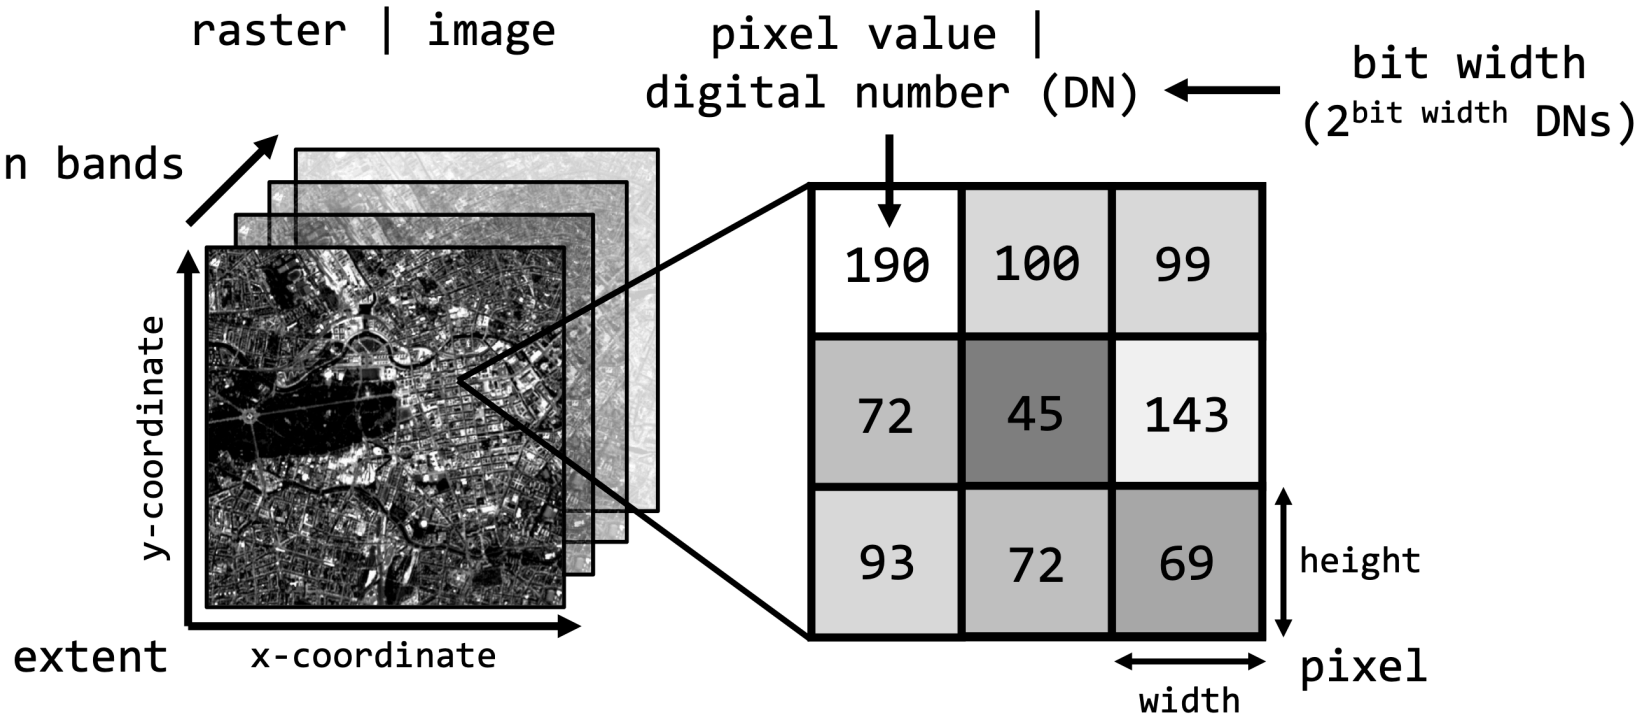

Dados vetoriais

O famoso ‘shapefile’ (geopackage é um formato muito melhor).

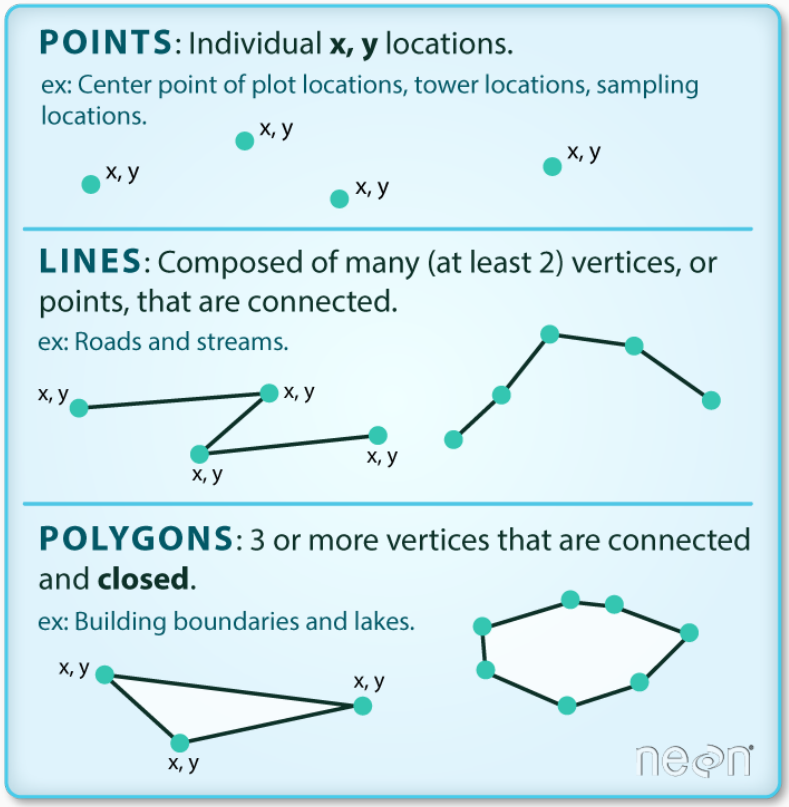

National Ecological Observatory Network (NEON)

Dados vetoriais

- Cada geometria de objeto é conectada a uma *tabela de atributos*.
- Uma tabela de atributos é uma tabela...e já sabemos fazer muita coisa com tabelas!

Casos problemáticos

- Polígono Multiparte

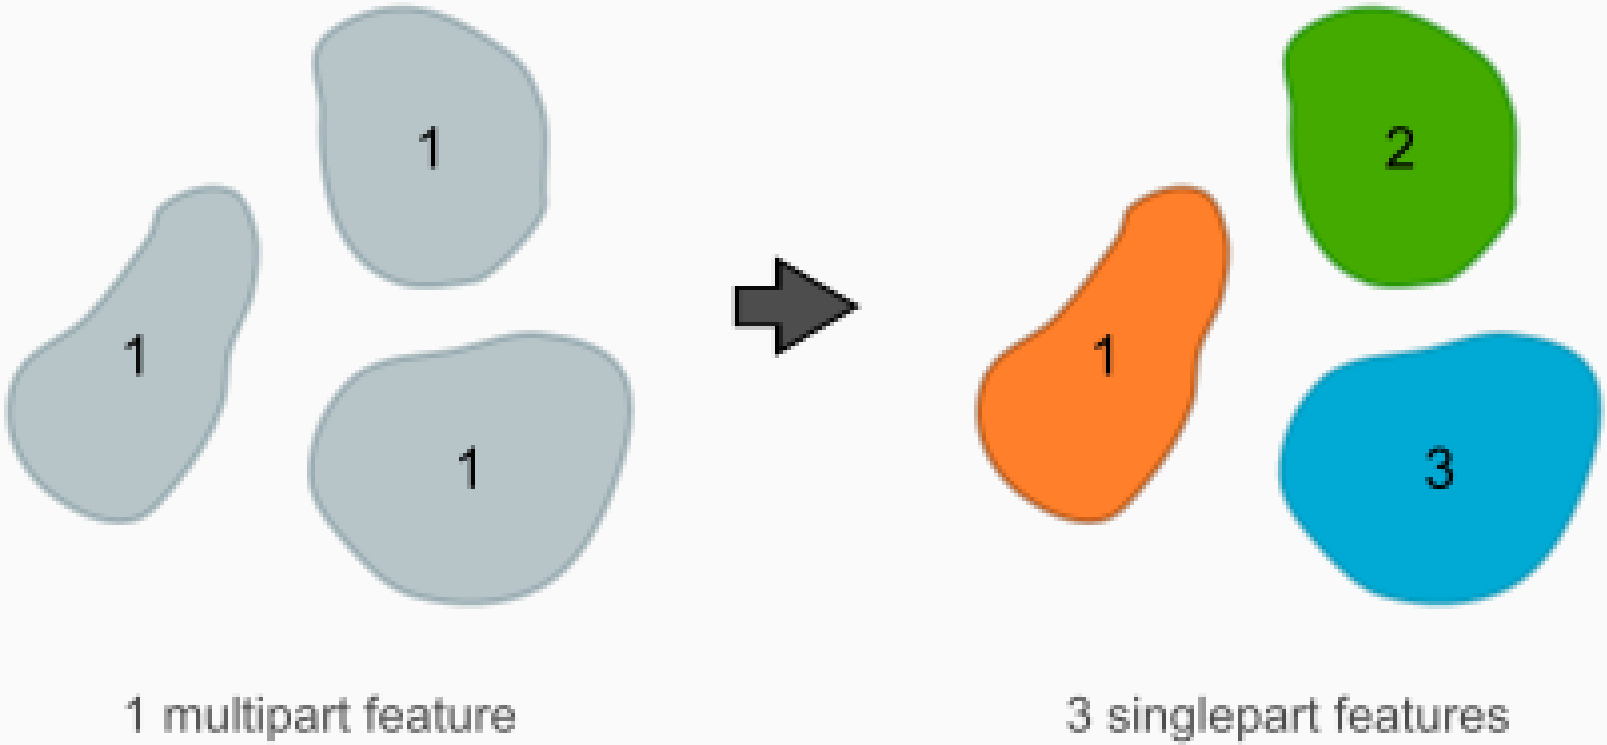

https://grass.osgeo.org/grass-stable/manuals/addons/v.multi2singlepart.html

Casos problemáticos

- Polígono em anel (ou ‘donut’)

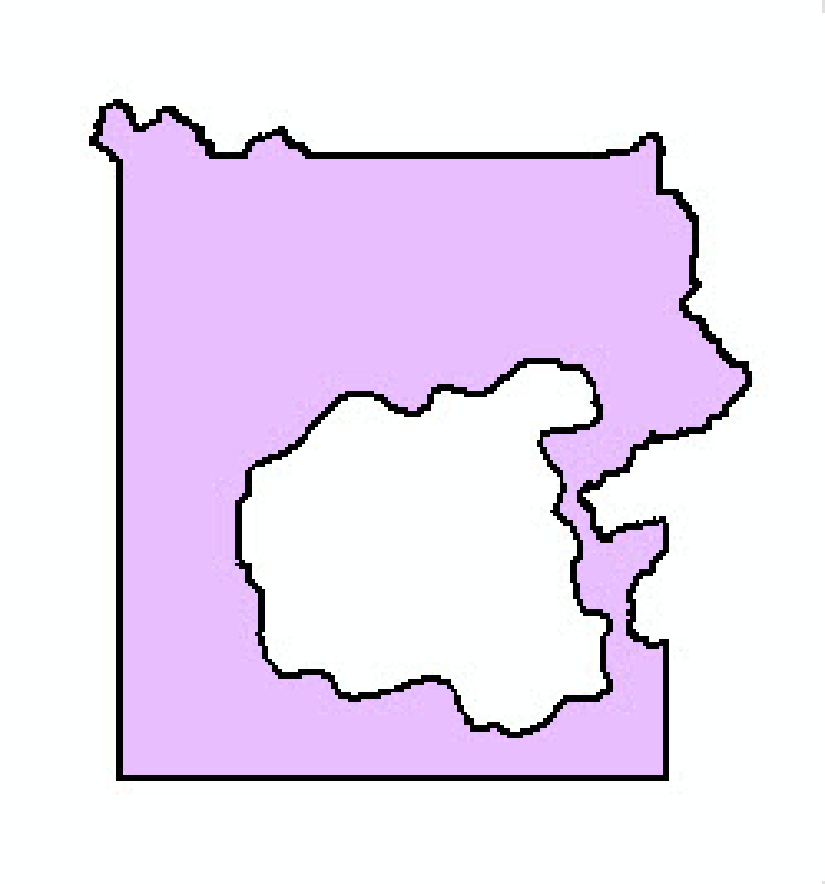

https://esri.github.io/geometry-api-java/doc/Polygon.html

Dados geoespaciais - sistema de coordenadas

- O que torna um dado espacial: *georeferenciamento*.
- Exige um **Sistema de Coordenadas de Referência** (Coordinate Reference System, CRS)
- A famosa "projecão"...

Dados geoespaciais - sistema de coordenadas

- O que torna um dado espacial: *georeferenciamento*.
- Exige um **Sistema de Coordenadas de Referência** (Coordinate Reference System, CRS)
- A famosa "projecão"...

- Um CRS inclui:
  - Datum
  - Projeção
  - Sistema de Coordenadas
  - Origem

O grande poster explicativo

- Preparado para minha disciplina de GIS
- Disponível na página do curso

Pacotes para geoprocessamento R

https://r-spatial.org/

A nova geração:

- `terra` (link):para rasters (mas também trabalha com vetores)
- `sf` (link): para vetores

Old school:

- `raster` (link): adivinhem pra que?
- `sp` (link): para vetores (mas também suporta rasters)

Adicionais

Utilidades:

- `RSToolbox` : https://bleutner.github.io/RStoolbox/
- `rsi` : https://docs.ropensci.org/rsi/index.html

Visualização:

- `mapview` : https://r-spatial.github.io/mapview/
- `tmap` : https://r-tmap.github.io/tmap/
- `ggmap` : https://paleolimbot.github.io/ggspatial/

Interface com a nuvem

Muito do sensoriamento remoto moderno envolve operações na nuvem ou em contato com a nuvem. Exemplos:

Google Earth Engine: `rgee` [1]

STAC catalogs: `rstac`

[1] usa o python por trás das cortinas.

Usando o `rstac` para acesar e baixar dados

Exemplo: Brazil Data Cube

Coleção CBERS4-MUX-2M-1: imagens compostas do sensor CBERS-4 MUX (20m) para períodos bimensais, usando o algoritmo CFMASK.

Parte II - Exemplos em R

Parte III - ML para classificação de imagens

Tipos de classificação

Existem dois grandes paradigmas de classificação de imagem (que também se aplicam ao machine learning):

- **Não-Supervisionada (*Unsupervised*):** o algoritmo tenta 'adivinhar' quem são as classes, e o usuário nomeia as classes *após* a classificação. Em ML e estatística é conhecido normalmente como *clustering*.
- **Supervisionada (*Supervised*):** o usuário define as classes *antes* da classificação, seleciona amostras que representam cada classe, e *treina* o algoritmo a reconhecer as classes.

Esse último parece familiar...

O único passo adicional é transformar as amostras em uma tabela:

Pixel	Banda 1	Banda 2	Banda 3	Classe
1	45	56	35	Agua
2	67	45	23	Agua
3	123	112	215	Solo
4	240	242	250	Urbano
5	12	16	8	Agua
6	67	32	56	Solo

E depois usar o modelo pra gerar uma predicao para todo o raster:

Pixel	Banda 1	Banda 2	Banda 3	Pred
1	45	56	35	Agua
2	67	45	23	Agua
3	123	112	215	Solo
4	240	242	250	Urbano
5	12	16	8	Agua
6	67	32	56	Solo

Mais um algoritmo de ML: *Support Vector Machines*

Algoritmo popular para classificação de imagens de sensoriamento remoto

- Desenvolvido na década de 90 n AT&T Bell Labs por Vladmir Vapnik
- Ideias originais desenvolvidas na Rússia na décadas de 60-70

Mais um algoritmo de ML: *Support Vector Machines*

Vantagens:

- Classificação e regressão
- Problemas Lineares e nào lineares com o 'truqe do kernel'
- Eficiente em espaços multidimensionais in high dimensional spaces.
- Eficiente também quando o numero de variaveis é maior que o de amostras.
- Usa apenas um subconjunto das amostras de treino na solução, então eficiente em memória

Support Vector Machines (SVM)

Princípio: o SVM tenta encontrar o melhor limiar de separação entre as classes.

- Para duas variáveis: uma linha
- Para três variáveis: um plano
- Para 4 ou mais variáveis: um *hiperplano*

Support Vector Machines (SVM)

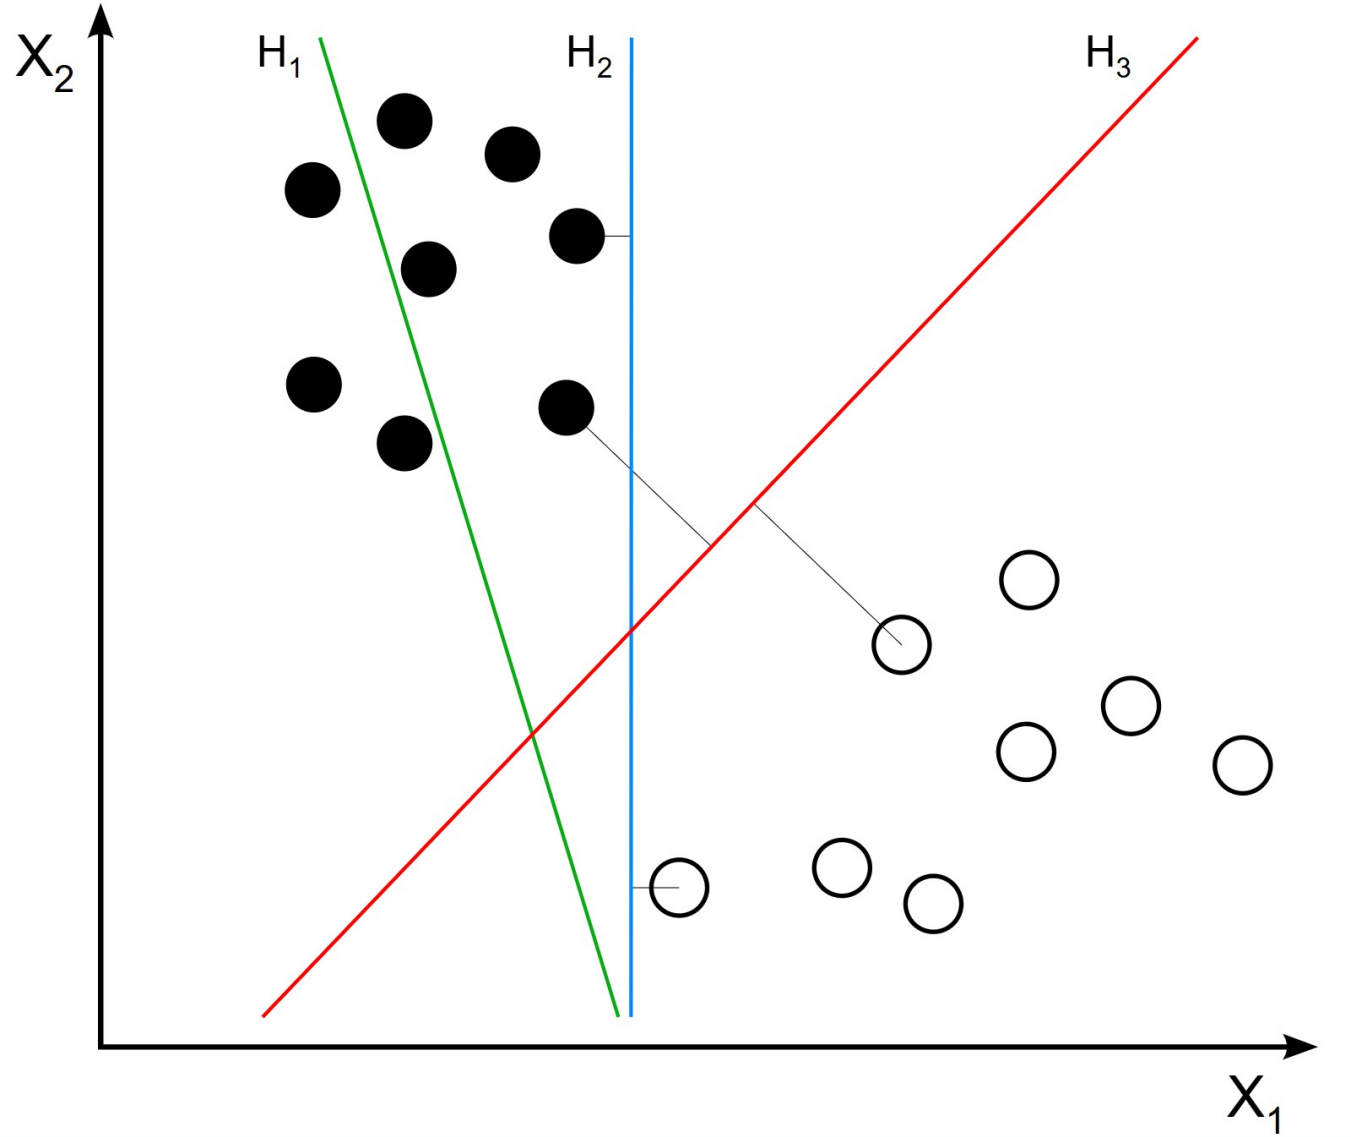

By User:ZackWeinberg, based on PNG version by User:Cyc - This file was derived from: Svm separating hyperplanes.png, CC BY-SA 3.0, https://commons.wikimedia.org/w/index.php?curid=22877598

Support Vector Machines (SVM)

Para identificar o hiperplano, o SVM foca apenas nos casos limítrofes. Essas amostras são os *vetores de suporte*.

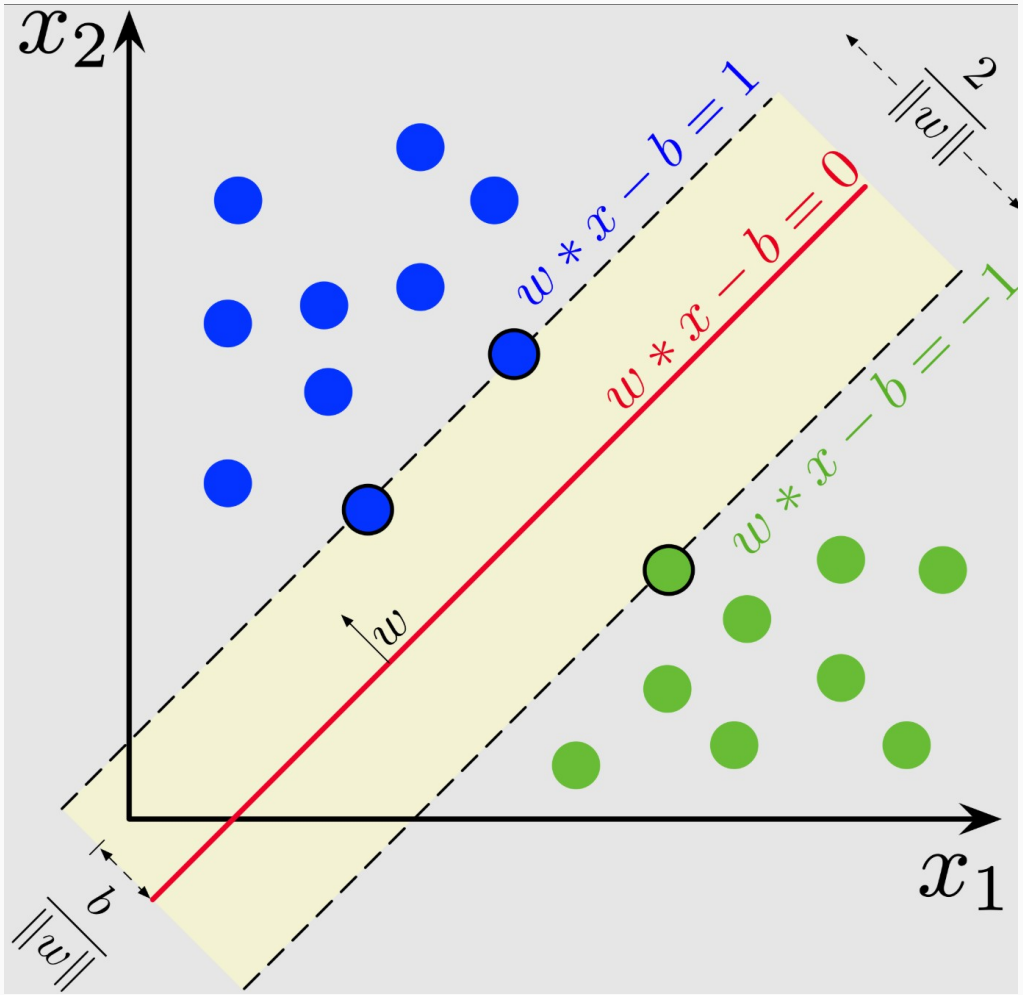

Exemplo interativo

https://greitemann.dev/svm-demo

Support Vector Machines (SVM)

Mas e se o problema não é linear?

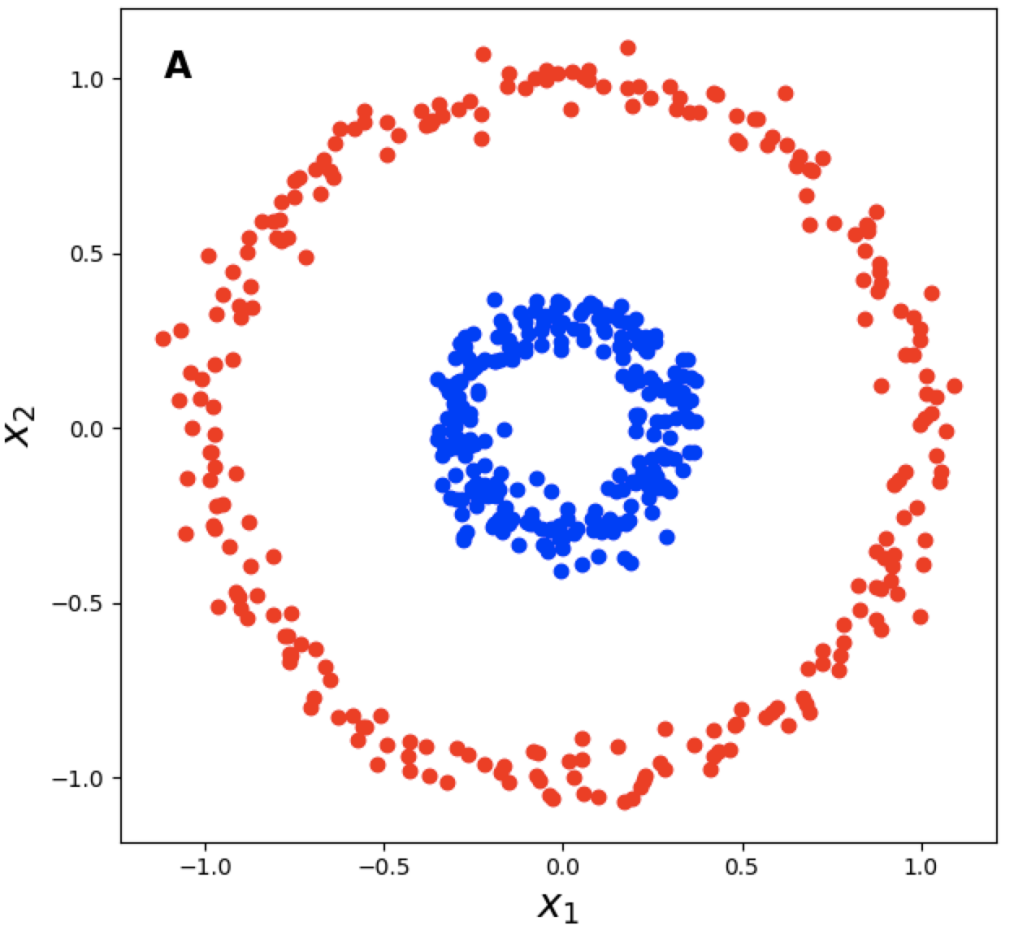

https://gregorygundersen.com/blog/2019/12/10/kernel-trick/

Support Vector Machines (SVM)

Podemos aplicar transformações matemáticas que separem os dados em outras dimensões.

Support Vector Machines (SVM)

Podemos aplicar transformações matemáticas que separem os dados em outras dimensões.

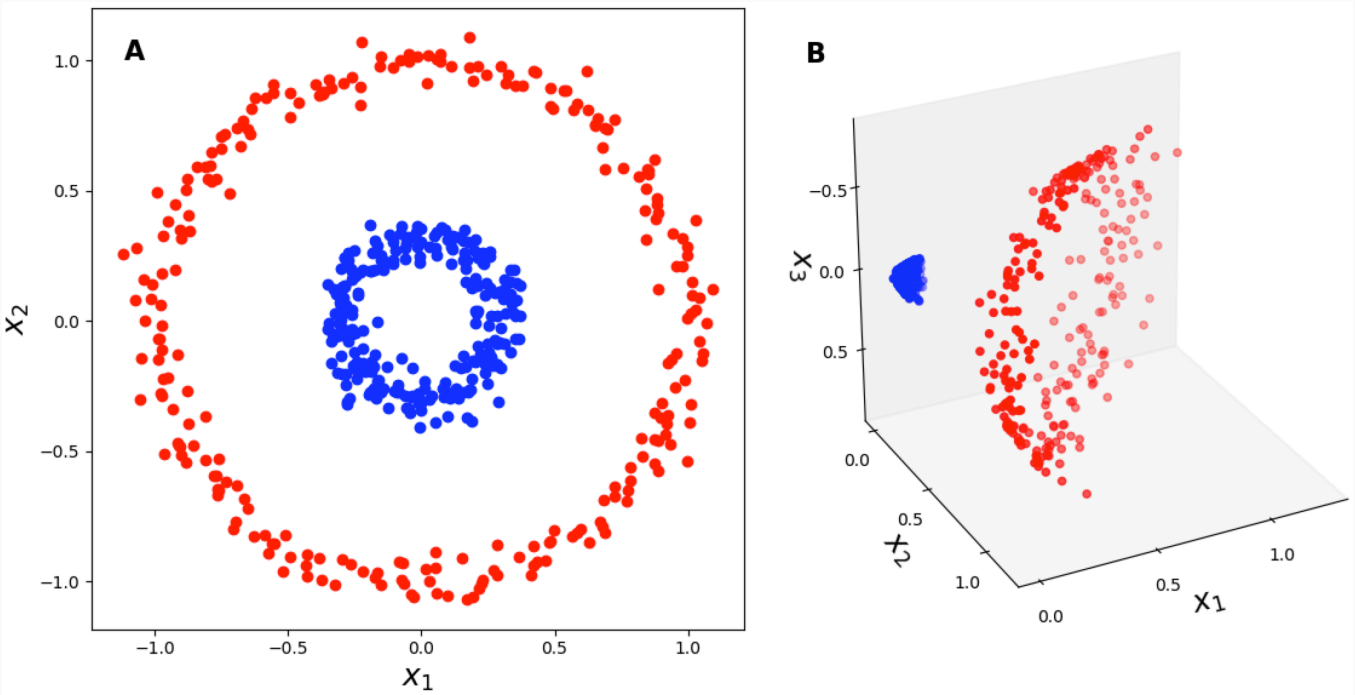

https://gregorygundersen.com/blog/2019/12/10/kernel-trick/

Support Vector Machines (SVM)

O *truque do kernel (kernel trick)* é um método matemático que permite ao SVM 'adivinhar' qual a melhor transformação para maximizar a separação dos dados. Diferentes funções de kernel podem ser utilizadas:

- **Linear:** apenas linhas/planos/hiperplanos. -**Polinomial**: permite curvas suaves.
- **Radial Basis Functions (RBF) / Gaussiano**: o mais comum, pois é extremamente flexível em se adaptar aos dados.

Existem outros, mas na prática o RBF é o mais usado.

https://greitemann.dev/svm-demo

Parâmetros do SVM

São aprendidos pelo modelo.

- Os vetores de suporte
- Os seus pesos (weights)
- O intercepto (viés)

Hiperparâmetros do SVM

Precisam ser otimizados.

- Kernel: linear, quadrático, etc.
- Custo (cost): controla a amplitude da *margem*.

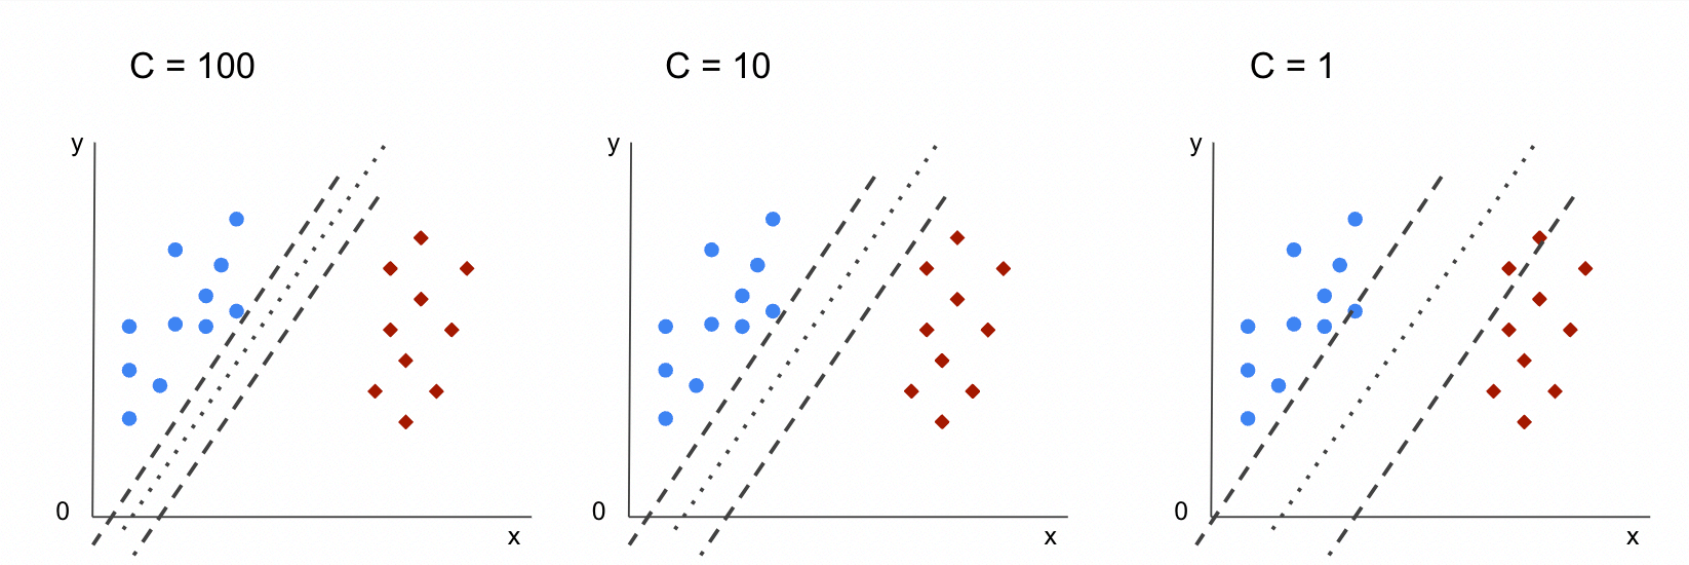

https://stackabuse.com/understanding-svm-hyperparameters/

Hiperparâmetros do SVM

Precisam ser otimizados.

- Kernel: linear, quadrático, etc.
- Custo (cost): controla a amplitude da *margem*.
- Regularização (γ ou σ): controla o 'detalhamento' das bordas de separação.

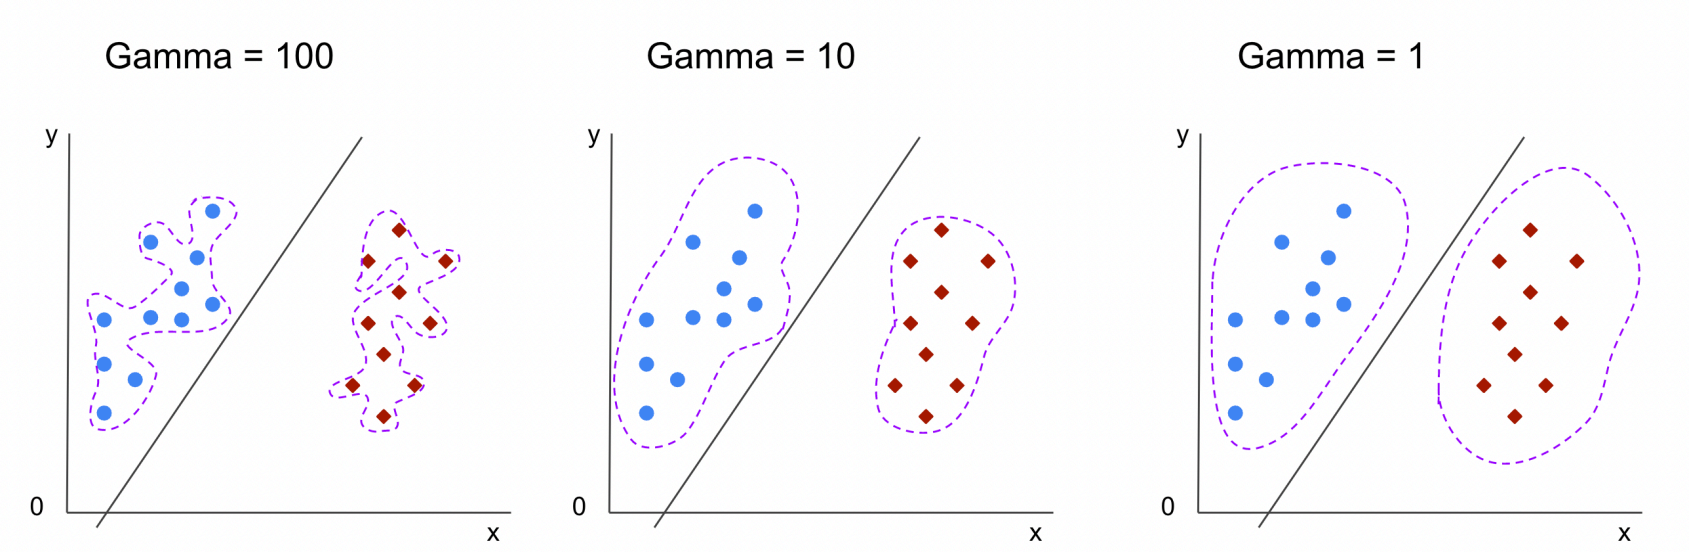

https://stackabuse.com/understanding-svm-hyperparameters/